

머신러닝



머신러닝


Section #

파이썬 기반의 머신러닝

데이터 분석


• What's Big Data?

대량의 데이터분석을 통해 일반적으로는 볼 수 없었던 새로운 **사실, 패턴 법칙을 발견하여** 새로운 비즈니스 가치를 창출하는 기법
= 기존 기법 + 새로운 기법



데이터 분석 절차



- 데이터 분석 방법론을 적용한 절차



인공지능

• 인공지능과 머신러닝의 관계

- 인공지능은 인간의 지능을 모방하여 사람이 하는 일을 컴퓨터(기계)가 할 수 있도록 하는 기술이다. 인공지능을 구현하는 방법으로 머신러닝이 있는 것이다.




머신러닝 기법의 종류

머신러닝 의 목적

지도학습(Supervisor Learning)

분류목적: 레코드의 특정 속성의 값이 범주형으로 정해져 있으며 데이터의 실체가 어떤 그룹에 속하는지 예측하는 기법

수치예측 ex) 회귀분석




비지도학습(Supervised Learning)

군집분석: 각 객체의 유사성이 높은 대상 집단을 분류하는 분석방법

연관분석

계층적 군집분석

비계층적 군집분석



지도 학습


분류분석의 절차

대량의 주어진 데이터의 패턴, 규칙 찾아(fitting=학습)내어 → **예측**

대략적으로 ~하다=평균 = 일반화



• 학습과정



오분류표(Confusion Matrix)

- 오분류표

CONFUSION MATRIX	ACTUAL	
	PREDICTED	
	True Positive (TP)	<u>False</u> Positive (FP)
	<u>False</u> Negative (FN)	True Negative (TN)

$$\text{Precision} = \frac{TP}{TP+FP}$$

$$\text{Accuracy} = \frac{TP+TN}{TP+FP+TN+FN}$$

$$\text{F1-Score} = \frac{2 * \text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$$

$$\text{Recall} = \frac{TP}{TP+FN}$$

오분류표(Confusion Matrix)


		실제 상태 또는 사실		
		영가설 참(H0) ex) 두 집단 간 차이가 없다. 처치의 효과가 없다.	영가설 거짓(H1) ex) 두 집단 간 차이가 있다. 처치의 효과가 있다.	total
검정 결과	영가설 채택	True Negative(TN) 영가설이 참인데, 영가설 채택 예) 1. 두 집단 간 실제 차이가 없는데, 두 집단 간 차이가 없다고 판정함 2. 처치의 효과가 실제 없는데, 처치의 효과가 없다고 판정함 (A)=10	False Negative(FN)=2종 오류 영가설이 거짓인데, 영가설 채택 예) 1. 두 집단 간 실제 차이가 있는데, 두 집단 간 차이가 없다고 판정함 2. 처치의 효과가 실제 있는데, 처치의 효과가 없다고 판정함 (B)=5	15
	영가설 기각	False Positive(FP)=1종 오류 영가설이 참인데, 영가설 기각 예) 1. 두 집단 간 실제 차이가 없는데, 두 집단 간 차이가 있다고 판정함 2. 처치의 효과가 실제 없는데, 처치의 효과가 있다고 판정함 (C)=90	True positive(TP) 영가설이 거짓인데, 영가설 기각 예) 1. 두 집단 간 실제 차이가 있는데, 두 집단 간 차이가 있다고 판정함 2. 처치의 효과가 실제 있는데, 처치의 효과가 있다고 판정함 (D)=895	985
total		100	900	1000

인공지능

• 인공지능과 머신러닝의 관계

- 인공지능은 인간의 지능을 모방하여 사람이 하는 일을 컴퓨터(기계)가 할 수 있도록 하는 기술이다. 인공지능을 구현하는 방법으로 머신러닝이 있는 것이다.

데이터 이해 > 제1장 데이터의 이해 > 5절 미래의 빅데이터





python 기반의 머신러닝

머신 러닝

Section #

회귀(Regression)분석

회귀분석

• 회귀분석

- 어떤 변수가 다른 변수에 의하여 설명된다고 보고, 그 함수 관계(대수적 관계)를 조사하는 통계학적 해석 수법
- 독립변수의 값에 의하여 종속변수의 값을 예측하기 위함, 인과관계
 - 독립변수(independent variable) : 종속변수에 영향을 미치는 변수 = 설명변수, 예측변수
 - 종속변수(dependent variable) : 분석의 대상이 되는 변수 = 반응변수, 결과변수

• 회귀모형의 추정


- 1) 실제 회귀 모형(알파, 베타, 엡실론은 각각 intercept, 회귀계수, 오차항을 의미)

$$Y_i = \alpha + \beta x_i + \varepsilon_i$$

- 2) 추정된 회귀 방정식

- 1)의 회귀모형은 실제값 Y를 표현한 식인데 비해
- 2)의 회귀방정식은 회귀모형에 의해 추정되는 Y값을 나타낸다.

$$\hat{y}_i = a + bx_i$$



회귀분석

• 회귀모형 종류

- 독립변수의 개수에 의한 구분 : 단순회귀분석, 다중회귀분석


종 류	모 형	설 명
단순회귀	$Y = \beta_0 + \beta_1 X + \epsilon$	독립변수가 하나이고 종속변수 Y 와의 관계가 직선
중회귀	$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \epsilon$	독립변수가 2개 이상 ($X_1, X_2, \dots, X_k$)이고 Y 와의 관계가 1차 선형 함수
곡선회귀	$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots + \beta_k X^k + \epsilon$	독립변수가 하나이고 Y 와의 관계가 2차 곡선 이상 ($k \geq 2$)
다항회귀	$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \beta_{11} X_1^2 + \beta_{22} X_2^2 + \dots + \beta_{kk} X_k^2 + \beta_{12} X_1 X_2 + \dots + \epsilon$	독립변수가 k 개이고 2차 다항회귀모형인 경우
비선형회귀	$Y = \beta_0 \log(\beta_1 X_1) + \beta_2 \sin(\beta_3 X_2) + \epsilon$	회귀계수들이 선형으로 표현되지 않는 모형. 이에 비하여 위의 네 가지는 모두 선형회귀모형이다.

회귀분석

• 회귀모형 과정의 의미






- 이 식을 기반으로 최소제곱법(L2)를 통해 최소제곱값을 최소화시키는 a,b를 찾는 방법이 회귀모형을 찾는 과정이자, 확장하여 머신러닝의 학습방법의 기반이 된다.

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - (a + bx_i))^2$$



• 회귀모형에 대한 가정


- ① 선형성 : 독립변수의 변화에 따라 종속변수도 변화하는 선형인 모형
- ② 독립성 : 잔차와 독립변수의 값이 관련되어 있지 않음
- ③ 등분산성 : 오차항들의 분포는 동일한 분산을 가짐
- ④ 잔차들간의 비상관성 : 잔차들끼리 상관이 없어야 함
- ⑤ 정상성 : 잔차항이 정규분포를 이뤄야 함



회귀분석


• 선형과 비선형의 원리

- 비선형 : 비선형 모델은 식 변형으로 변수들을 선형 결합화 시킬 수 없는 모델을 말한다.
- 선형성(Linearity principle)의 원리란 중첩의 원리(principle of superposition)가 적용된다는 의미를 갖는다.



<선형의 예>

위에서 적힌 것처럼 어떤 선형함수에 6을 집어넣었을 때의 함수 값을 같은 함수에 1과 5을 넣었을 때의 함수 값을 합한 값으로 알 수 있다.



<비선형의 예>


위에서 보는 것처럼 비선형함수는 중첩의 원리가 성립하지 않으므로, 함수의 수식이 알려지지 않았을 때, 함수 값을 예측하기가 매우 어렵다는 특징이 있다.

회귀분석



- 등분산성을 만족하지 못하는 경우

- 등분산성 : 설명변수(x)에 대한 잔차의 산점도를 그렸을 때, 첫번째 그림과 같이 설명변수(x) 값에 관계없이 잔차들의 변동성이 일정한 형태를 보이면 선형회귀분석의 가정 중 등분산성을 만족한다고 볼 수 있다.(교재 p310)

x 가 일정해 많 등분산성



X




X

비선형

회귀분석

회귀분석 모형에서 확인할 사항

- 모형이 통계적으로 유의미한가? F분포값과 유의확률(p-value)를 확인
- 회귀계수들이 유의미한가? 회귀계수의 **t값과 유의확률(p-value)**를 확인
- 모형이 얼마나 설명력을 갖는가? **결정 계수**를 확인
- 모형이 데이터를 잘 적합하고 있는가? 잔차통계량을 확인하고 회귀진단



<설명계수 R^2> → 종속변수의 분산 중에서 독립변수에 의해 설명된 분산 비율

>summary() #summary() 함수를 통해 결정계수, F통계량, 잔차의 표준오차 등 주요 통계량의 정보 출력

Call :

lm(formula = weight ~ Time, data = chick) #선형회귀:lm(종속변수~독립변수, 데이터)

Residuals :

	Min	1Q	Median	3Q	Max
	-14.3202	-11.3081	-0.3444	11.1162	17.5346

Coefficient :

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	24.4654	6.7279	3.636	0.00456 **
Time	7.9879	0.5236	15.255	2.97e-08 ***

#Time 회귀계수가 7.9879이므로 Time 1이 증가할 때, 종속변수 weight가 7.9879만큼 증가

Signif. codes : 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error : 12.29 on 10 degrees of freedom

Multiple R-squared : 0.9588, Adjusted R-squared : 0.9547

F-statistic : 232.7 on 1 and 10 DF, p-value : 2.974e-08

#F통계량=232.7이며, p-value=2.974e-08이므로 통계적으로 유의함

#결정계수가 약 95%로 매우 높으므로 회귀계수를 유의함

회귀분석

• 다중공선성(Multicollinearity)

- 모형의 일부 예측변수가 다른 예측변수와 상관되어 있을 때 발생하는 조건이다.
- 중대한 다중공선성은 회귀계수의 분산을 증가시켜 불안정하고 해석하기 어렵게 만들기 때문에 문제가 된다.
- R에서는 vif 함수를 이용해 VIF값을 구할 수 있으며, **보통 VIF값이 4가 넘으면 다중 공선성이 존재한다고 본다.**
- **해결방안 : 높은 상관 관계가 있는 예측변수를 모형에서 제거한다.**

$$VIF_k = \frac{1}{1 - R_k^2}$$

• 최적 회귀방정식의 선택 : 단계별 변수선택(Stepwise Variable Selection)

- 후진 제거법(Backward Elimination) : 기준 통계치에 가장 도움이 되지 않는 변수를 하나씩 제거하는 방법
- 전진 선택법(Forward Selection) : 기준 통계치를 가장 많이 개선시키는 변수를 차례로 추가하는 방법
- 단계별 선택법(Stepwise Selection) : 모든 변수가 포함된 모델에서 기준 통계치에 도움되지 않는 변수를 삭제하거나, 모델에 빠진 변수 중 통계치를 개선시키는 변수를 추가하는 방법

• 회귀모델에서 변수를 선택하는 판단 기준

- Cp(멜로우스 통계량), AIC(아카이케), BIC(슈바르츠 통계량)을 기준으로 세 통계량이 작을 수록 좋다.

회귀분석(Regression)

데이터 분석 > 2장 통계분석

회귀분석 실습

회귀분석

Chick :

식이요법 Diet 별로

chick의 체중변화 체크

```
>summary() #summary() 함수를 통해 결정계수, F통계량, 잔차의 표준오차 등 주요 통계량의 정보 출력
```

```
Call :
```

```
lm(formula = weight ~ Time, data = chick) #선형회귀:lm(종속변수~독립변수, 데이터)
```

```
Residuals :
```

	Min	1Q	Median	3Q	Max
	-14.3202	-11.3081	-0.3444	11.1162	17.5346

```
Coefficient :
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	24.4654	6.7279	3.636	0.00456 **
Time	7.9879	0.5236	15.255	2.97e-08 ***

#Time 회귀계수가 7.9879이므로 Time 10이 증가할 때, 종속변수 weight가 7.9879만큼 증가

```
---
```

```
Signif. codes : 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error : 12.29 on 10 degrees of freedom
```

```
Multiple R-squared : 0.9588, Adjusted R-squared : 0.9547
```

```
F-statistic : 232.7 on 1 and 10 DF, p-value : 2.974e-08
```

#F통계량=232.7이며, p-value=2.974e-08이므로 통계적으로 유의함

#결정계수가 약 95%로 매우 높으므로 회귀계수를 유의함

p. 138 ~

회귀분석(Regression)

데이터 분석 > 2장 통계분석

• 회귀분석 결과해석

① 모형이 통계적으로 유의미한가? F-분포값과 유의확률(p-value)

- 유의 확률이 0.05 보다 작으면 유의미

② 회귀계수들이 유의미한가? 회귀계수 t값과 유의확률

③ 모형의 설명력 : 결정계수

- 결정계수가 1에 가까울 수록 유의미

④ 데이터 적합성 : 잔차 통계량, 회귀진단

회귀분석(Regression)





데이터 분석 > 2장 통계분석

회귀모형 진단

- 모형 진단 그래프

```
data(cars)
m<-lm(dist~speed, cars)
par(mfrow=c(2,2))
plot(m)
```

등분산성은 잔차들이 퍼져있는 정도가 동일한지를 보는 것이므로 하나의 x값에 나타난 가장 큰 값과 가장 작은 값 사이의 격차가 유사하면 등분산성을 만족한 것이며, 빨간색 실선은 잔차의 추세를 나타낸다. 빨간색 실선이 점선에서 크게 벗어난다면 예측 값에 따라 잔차가 크게 달라진다는 것이다









회귀분석(Regression)

- 회귀모형 진단

- Q-Q(Quantile-Quantile Plot) plot

- 분위수(Quantile)란 데이터의 분포에서 전체 넓이를 일정 비로 나누어 위치에 있는 값으로 사분위(Quartile)와 다른 것
 - qqplot에서도 분위수 개념이 적용된다.
qqplot은 표준정규분포의 분위수와 이에 대응하는 분포(측정한 실제 데이터의 분포)의 분위수를 x, y 좌표평면에 plotting하는 개념이다.



데이터 분석 > 2장 통계분석

회귀분석(Regression)

데이터 분석 > 2장 통계분석

• 회귀모형 진단


- 모형 진단 그래프

- ① Residuals vs Fitted : y축(Residuals)은 잔차. 선형회귀에서 오차는 평균이 0이고 분산이 일정한 정규분포를 가정하므로 y값은 기울기가 0인 직선이 이상적.
- ② Normal Q-Q : 잔차가 정규분포를 잘 따르고 있는가. 잔차들이 그래프 선상에 있어야 이상적.
- ③ Scale-Location : y축(standard residual)은 표준화 잔차. 이 또한 기울기가 0인 직선이 이상적. 0에서 멀리 떨어진 값은 이상치일 가능성이 높음.
- ④ Residuals vs Leverage : 모형에 막대한 영향을 끼치는 값을 찾을 때, 즉 영향력이 큰 값을 찾아냄. Cook's Distance가 그래프 내에 점선으로 표시되어 있는데, Cook's Distance 안에 위치하면 특별히 튀는 값 없음.

* **Cook's Distance** : 하나의 관측치가 모형에 미치는 영향력을 나타내는 척도. 전체 데이터로부터 얻은 회귀계수들과 i 번째 관측치를 제거하고 얻은 회귀계수들의 차이를 측정하거나 동일하게 전체 데이터로부터 얻은 적합값들과 i 번째 관측치를 제거하고 얻은 적합값들의 차이를 측정하여 계산. 만약 어떤 관측개체의 영향력이 크다면 그 개체를 제외할 때, 회귀분석의 결과에 큰 변화가 일어날 것이며 따라서 C_i 의 값이 커지게 될 것.

⇒ 잔차모형이 비선형일 때, 다른 새로운 변수 추가, 로그 또는 지수 변수 변환, 선형성을 만족하지 못하는 변수 제거, 회귀분석의 단계별 변수선택 방법 등을 고려할 수 있다.

회귀분석(Regression)




기출문제

모의고사

아래의 Q-Q plot 중 가장 정규분포와 가장 가까운 것은 무엇인가?

- ① 가
- ② 나
- ③ 다
- ④ 라



회귀분석(Regression)

데이터 분석 > 2장 통계분석


- 회귀모형 진단
- 모형 진단 그래프

- 쿡의 거리는 표준화된 잔차의 합

$$\text{Cook's Distance } D_i = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(i)})^2}{pMSE}$$



※ p 는 예측변수의 수
 $\hat{y}_j$ 는 j 번째 회귀분석 결과
 $\hat{y}_{j(i)}$ 는 i 번째 관측치를 제외한 j 번째 회귀분석 결과



<https://blog.naver.com/lingua/2219091989>

회귀분석(Regression)

데이터 분석 > 2장 통계분석

• 설명변수 선택법(최적 회귀방정식 선택)

1) 모든 조합 회귀분석 : 모든 가능한 독립변수들의 조합에 대한 회귀모형을 고려해 AIC나 BIC의 기준으로 가장 적합한 회귀모형 선택


2) 단계별 변수 선택(Stepwise Variable Selection) → **step()함수 이용**

① 단계별 선택법(Stepwise Selection) : 모든 변수가 포함된 모델에서 출발하여 기준 통계치에 가장 도움이 되지 않는 변수를 삭제하거나, 모델에서 빠져 있는 변수 중에서 기준 통계치를 가장 잘 개선시키는 변수 추가

② 후진 제거법(BackWard Elimination) : 모든 변수가 포함된 모델에서 기준 통계치가 가장 도움이 되지 않는 변수를 하나씩 제거

③ 전진 선택법(Forward Selection): 절편만 있는 모델에서 기준 통계치를 가장 많이 개선시키는 변수를 차례로 추가하는 방법

회귀분석(Regression)



데이터 분석 > 2장 통계분석

• 설명변수 선택법(전진선택법)

#전진 선택법

#변수제거 없는 회귀분석부터 시작하여 (1)

Start: AIC=71.44

y ~ 1

	Df	Sum of Sq	RSS	AIC
+ x4	1	1831.90	883.87	58.852
+ x2	1	1809.43	906.34	59.178
+ x1	1	1450.08	1265.69	63.519
+ x3	1	776.36	1939.40	69.067
<none>			2715.76	71.444

#AIC가 가장 작은(종속변수에 가장 큰 영향을 미치는) 독립변수부터 y에 포함을 시키며 (x4)

Step: AIC=58.85

y ~ x4

	Df	Sum of Sq	RSS	AIC
+ x1	1	809.10	74.76	28.742
+ x3	1	708.13	175.74	39.853
<none>			883.87	58.852
+ x2	1	14.99	868.88	60.629

	Df	Sum of Sq	RSS	AIC
+ x2	1	26.789	47.973	24.974
+ x3	1	23.926	50.836	25.728
<none>			74.762	28.742

Step: AIC=24.97

y ~ x4 + x1 + x2

	Df	Sum of Sq	RSS	AIC
<none>			47.973	24.974
+ x3	1	0.10909	47.864	26.944

#x3까지 모두 포함되었으므로 중단하고 분석 시작

Call:

lm(formula = y ~ x4 + x1 + x2, data = df)

Coefficients:

(Intercept)	x4	x1	x2
71.6483	-0.2365	1.4519	0.4161

#최종 회귀식은 $y = 71.6483 - 0.2365x_4 + 1.4519x_1 + 0.4161x_2$

회귀분석

- 정규화 선형회귀(Regularized Linear Regression)

- 선형회귀계수에 대한 **제약 조건을 추가**하여 모형이 과도하게 최적화되는, 즉 **과적합(overfitting)**을 막는 방법

- Lasso 회귀분석 ★

- 회귀분석에서 사용하는 최소제곱법에 제약조건을 부여하는 방법이다.
- **회귀계수의 절대값이 클수록 패널티를 부여**한다.
- 정규화 선형회귀 (Regularized Linear Regression) 의 하나로 선형회귀계수에 대한 제약 조건을 추가하여 과적합을 막는 방법 중 하나이다.
- 람다는 기존의 잔차 제곱합과 추가적으로 제약 조건의 비중을 조절하기 위한 hyper parameter 이다. (람다가 크면 정규화 정도가 커지고 가중치의 값들이 작아진다 = 과소적합의 문제가 발생)
- 제약조건 t는 회귀계수 값에 대해 축소 정도를 조절할 수가 있다.
- MSE(평균제곱오차, mean squared error)와 **패널티(penalty)항의 합이 최소가 되게 하는 파라미터를 찾는 것이 목적**이다.
- Lasso regression은 L1 norm을 사용해서 패널티를 주는 방식이다.
- L1 Regularization 은 기존 Cost function 뒤에 L1 항을 추가해준 것이다.

회귀분석(Regression)

9. 회귀분석의 검정

2장 통계분석

예제

- 10년간 에어컨 예약대수와 판매대수 (단위 : 1,000대)

예약대수(X)	19	23	26	29	30	38	39	46	49
판매대수(Y)	33	51	40	49	50	69	70	64	89

- 위의 데이터에 대해 단순회귀분석을 실시하여 검정을 실시한다.

```
> x<-c(19, 23, 26, 29, 30, 38, 39, 46, 49)
> y<-c(33, 51, 40, 49, 50, 69, 70, 64, 89)
> lm(y~x)
```

```
Call:
lm(formula = y ~ x)
```

```
Coefficients:
(Intercept)      x
        6.409      1.529
> summary(lm(y~x))
```

```
Call:
lm(formula = y ~ x)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-12.766  -2.470  -1.764   4.470   9.412
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   6.4095     8.9272   0.718 0.496033
x              1.5295     0.2578   5.932 0.000581 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 7.542 on 7 degrees of freedom
Multiple R-squared:  0.8341,    Adjusted R-squared:  0.8104
F-statistic: 35.19 on 1 and 7 DF, p-value: 0.0005805
```




회귀분석(Regression)

데이터 분석 > 2장 통계분석

9. 회귀분석의 검정

• 결정계수



$$SST = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$SSR = SST - SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- 전체제곱합(total sum of squares, SST) : $\sum_{i=1}^n (y_i - \bar{y})^2$
- 회귀제곱합(regression sum of squares, SSR) : $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
- 오차제곱합(error sum of squares, SSE) : $\sum_{i=1}^n (y_i - \hat{y}_i)^2$
- 결정계수(R^2)는 전체제곱합에서 회귀제곱합의 비율(SSR/SST), $0 \leq R^2 \leq 1$ (여기서 $SST = SSR + SSE$)
- 결정계수(R^2)는 전체 데이터를 회귀모형이 설명할 수 있는 설명력을 의미한다.
(단순회귀분석에서 결정계수는 상관계수 r의 제곱과 같다)

회귀분석(Regression)

데이터 분석 > 2장 통계분석

• 회귀분석의 검정

• 회귀직선의 적합도 검토

- 결정계수(R^2)를 통해 추정된 회귀식이 얼마나 타당한지 검토한다.
(결정계수(R^2)가 1에 가까울수록 회귀모형이 자료를 잘 설명함)
- 독립변수가 종속변수 변동의 몇 %를 설명하는지 나타내는 지표이다.
- 다변량 회귀분석에서는 독립변수의 수가 많아지면 결정계수(R^2)가 높아지므로 독립변수가 유의하든, 유의하지 않든 독립변수의 수가 많아지면 결정계수가 높아지는 단점이 있다.
- 이러한 결정계수의 단점을 보완하기 위해 수정된 결정계수(R_a^2 : adjusted R^2)를 활용한다.
수정된 결정계수는 결정계수보다 작은 값으로 산출되는 특징이 있다.

$$\begin{aligned}
 \text{수정된 결정계수 } R_a^2 &= 1 - \frac{(n-1)(1-R^2)}{n-k-1} \\
 &= 1 - \frac{(n-1) \times \left(\frac{SSE}{SST} \right)}{n-k-1} \\
 &= 1 - (n-1) \frac{MSE}{SST} \quad (k: \text{독립변수 개수}, n: \text{데이터의 개수})
 \end{aligned}$$

회귀분석

• Regression

- 회귀분석(Regression analysis)은 관찰된 연속형 변수들에 대해 두 변수 사이의 모형을 구한 뒤, 적합도를 측정해 내는 분석으로 변수 사이의 관계를 알아내는 방법이다.
- Cost Function(Loss Function)은 그래프(가설)와 점(데이터) 사이에 거리가 멀면 가설이 잘못되었다는 것이고, 가까울수록 가설이 일치한다는 의미이며 이러한 거리를 측정하는 것을 Cost Function 혹은 Loss Function 이라고 표현한다.

• Regression 성능 지표

① RMSE(Root Mean Square Error)

- 표준편차와 비슷한 의미로 작을수록 모델의 성능이 우수하다고 평가할 수 있다.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

② MSE(Mean Square Error)

- RMSE와 의미가 크게 다르지 않으며, 표준 편차와 비슷한 의미이며 작을수록 성능이 우수하다고 평가할 수 있다.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

회귀분석

- Regression 성능 지표

- ① MAE(mean Absolute Error)

- 실제 값과 예측 값의 차이의 절대 값의 평균값을 지표로 사용하는 지표이다.

$$\text{MAE}(X, h) = \frac{1}{m} \sum_{i=1}^m |h(x^{(i)}) - y^{(i)}|$$

- ② MAPE(MEAN Absolute Error)

- MAPE의 산식은 A_t 는 실제 값이고 F_t 는 예측 값이다. MAPE는 예측값과 실제값을 빼준 후, 이를 실제 값으로 나눈 값을 모두 더한 뒤, n 으로 나눠준다. 그리고 백분율로 변환하기 위해 100을 곱해준다.
 - 백분율 오차는 $P_t = 100E_t/Y_t$ 으로 주어지고, 백분율 오차는 단위와 관련이 없는 값을 도출하므로 데이터 모음사이의 예측 성능을 비교할 때 많이 사용한다.

$$M = \frac{100}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right|$$

45. [단답형] 아래 Hitters 데이터프레임은 1966 ~ 1967 년 시즌 메이저리그 야구 선수에 대한 데이터이다. 아래의 회귀분석 결과에서 설명력이 가장 높은 변수를 쓰시오

```
아래
> summary(lm(Salary~., hitters))

Call:
lm(formula = Salary ~ ., data = hitters)

Residuals:
    Min       1Q   Median       3Q      Max
-982.81 -187.84  -35.66  130.61 1947.43

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 126.10553   83.62448   1.508 0.132838
AtBat      -2.20302    0.63605  -3.464 0.000629 ***
Hits       7.82776    2.40198   3.259 0.001276 **
HmRun      2.16355    6.23618   0.347 0.728937
Runs      -2.09957    3.00849  -0.698 0.485911
RBI       -0.02292    2.61033  -0.009 0.993003
Walks      6.15106    1.84028   3.342 0.000960 ***
Years     -2.59237   12.45401  -0.208 0.835200
CAtBat    -0.17628    0.13667  -1.290 0.198325
CHits     0.06976    0.67874   0.103 0.918221
CHmRun   -0.23309    1.63561  -0.143 0.886795
CRuns     1.61005    0.75162   2.142 0.033168 *
CRBI      0.80143    0.70000   1.145 0.253367
CWalks   -0.79394    0.33243  -2.388 0.017681 *
PutOuts   0.29457    0.07830   3.762 0.000211 ***
Assists   0.38400    0.22383   1.716 0.087499 .
Errors   -2.87871    4.42077  -0.651 0.515539
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 319.9 on 246 degrees of freedom
Multiple R-squared:  0.5279, Adjusted R-squared:  0.4972
F-statistic: 17.19 on 16 and 246 DF, p-value: < 2.2e-16
```

정답 → Hits : 회귀 계수의 절대값이 가장 높은 변수

31. [데이터 분석] Default 데이터는 10,000명 의 신용카드 고객에 대한 체납 여부(default)와 학생여부(student), 카드잔고(balance), 연봉(income)을 포함하고 있다. 고객의 체납 확률을 예측하기 위한 아래 결과에 대한 설명으로 가장 부적절한 것은?

아래

```
> model<-glm(default~., data=Default, family="binomial")
> summary(model)

Call:
glm(formula = default ~ ., family = "binomial", data = Default)

Deviance Residuals:
    Min       1Q   Median       3Q      Max 
-2.4691  -0.1418  -0.0557  -0.0203   3.7383 

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -1.087e+01  4.923e-01 -22.080  < 2e-16 ***
studentYes  -6.468e-01  2.363e-01  -2.738  0.00619 **
balance      5.737e-03  2.319e-04  24.738  < 2e-16 ***
income       3.033e-06  8.203e-06   0.370  0.71152
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 2920.6  on 9999  degrees of freedom
Residual deviance: 1571.5  on 9996  degrees of freedom
AIC: 1579.5

Number of Fisher Scoring iterations: 8
```

- ① 해당 분석 결과에 대한 분산분석표를 확인하기 위해서는 anova(model)을 실행하면 된다
- ②  카드 잔고와 연봉이 동일한 수준일 때, 학생(studentYes)이 학생이 아닌 고객보다 체납확률이 높다
- ③ 로지스틱 회귀모형을 사용한 결과이다
- ④ 세 설명 변수 모두 체납확률을 예측하는데 유의한 영향이 있지는 않다.

Estimate 값을 보면 음수로 되어 확률이 낮아짐을 알 수 있으므로 카드 잔고와 연봉이 동일한 수준일 때, 학생(studentYes)이 학생이 아닌 고객보다 체납확률이 낮다.

Section #

Logistic Regression (로지스틱 회귀분석)

Logistic Regression (로지스틱 회귀분석)


- 반응변수가 범주형인 경우 적용되는 회귀분석 모형
- 선형회귀분석이 직접적인 수치를 예측하는 것과 달리 **목표변수 Y가 특정 범주에 속할 확률 $P(Y=i)$ 인 것이다.**
- 즉 설명변수의 값이 주어질 때 목표변수의 각 범주에 속할 확률이 얼마인지를 추정하여 추정 확률을 기준치에 따라 분류하는 목적으로 사용한다.
- 모형의 적합을 통해 **추정된 확률**을 사후확률(posterior probability) 라고도 한다.
- 보통 로지스틱 분석에서는 예측하고자 하는 목표변수 Y의 범주가 0, 1 두 가지가 있다고 가정하고 목표변수 Y의 범주가 1이 될 확률 $P(Y=1) = P(Y)$ 로 표기하면,



$$\frac{P(Y)}{1 - P(Y)} = \exp(\beta_0 + \beta_1 X)$$

오즈

$$\log\left(\frac{P(Y)}{1 - P(Y)}\right) = \beta_0 + \beta_1 X$$




- 위 식의 좌변 $P(Y) / 1 - P(Y)$ 을 오즈 (odds) 라고 부른다.
즉 오즈는 추정모형에 $\exp(\text{지수})$ 함수를 취한 것이다.
- 좌변은 확률들의 비율이고, 우변은 지수함수의 형태이므로, $(0 \sim \infty)$ 의 범위를 가진다. 이에 좌변 및 우변 모두 $(-\infty, \infty)$ 의 범위를 가지게 하기 위해 양변에 $\log$ 함수를 취하면 위 두 번째 식이 된다.

Logistic Regression (로지스틱 회귀분석)

- 우변은 선형모델이고, 좌변은 log 함수이므로 $(-\infty, \infty)$ 의 범위를 가진다.
- 첫 번째 식에서 $P(Y)$ 에 대해 정리하면 아래와 같다.

$$P(Y=1) = \frac{e^{(\beta_0 + \beta_1 X)}}{1 + e^{(\beta_0 + \beta_1 X)}} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X)}}$$




- 즉, 로지스틱 회귀분석은 주어진 데이터에서 목표변수 Y 가 범주 값이 1일 확률 (정확히 얘기하자면 범주 값이 더 큰 값을 가질 확률) 을 위 함수를 이용하여 모형을 수립하고 **모수 β_0, β_1 들을 추정하는 알고리즘이라고** 할 수 있다.

이러한 모수 β_0, β_1 추정에는 일반적으로 **최대우도추정법(Maximum Likelihood Estimation)** 을 사용하고, 이는 수식을 변형하는 것 등의 해석학적 방법으로 직접 계산하기 어려우므로 일정 초기값을 부여한 뒤 이를 반복적으로 계산하여 값을 조정해 가는 수치 계산적 방법으로 추정하게 된다.

Logistic Regression (로지스틱 회귀분석)

- 아래는 로지스틱 함수의 그래프이다. Y 축은 목표변수 Y 의 발생확률이므로 0~1 의 값을 가지고 X 축은 $(-\infty, \infty)$ 의 값을 가진다.
- 그래프의 모양은 β 값에 따라 달라진다. β 가 (-) 값이면 그래프가 Y축 기준으로 반대모양이 될 것이다.



- 따라서 이항 반응변수 Y 에 대해 다중 로지스틱 회귀모형의 일반적인 형태는 아래와 같다.

$$\log\left(\frac{\pi(x)}{1 - \pi(x)}\right) = \alpha + \beta_1 x_1 + \dots + \beta_k x_k$$

$$\pi(x) = P(Y = 1), x = (x_1, \dots, x_k)$$

Logistic Regression (로지스틱 회귀분석)

• 로지스틱 회귀분석 실전 분석

※ [오즈비 ; Odds Ratio]

: 오즈는 성공할 확률이 실패할 확률의 몇 배 인지를 나타내는 확률,

오즈비는 오즈의 비율

```
> mydata$rank <- factor(mydata$rank)
> mylogit <- glm(admit ~ gre + gpa + rank, data = mydata, family = "binomial")
> summary(mylogit)
```

```
> summary(mylogit)
Call:
glm(formula = admit ~ gre + gpa + rank, family = "binomial",
    data = mydata)

Deviance Residuals:
    Min       1Q   Median       3Q      Max
-1.6268  -0.8662  -0.6388   1.1490   2.0790

Coefficients:
(Intercept)  -3.989979  1.139951  -3.500  0.000465 ***
gre           0.002264  0.001094   2.070  0.038465 *
gpa           0.804038  0.331819   2.423  0.015388 *
rank2        -0.675443  0.316490  -2.134  0.032829 *
rank3        -1.340204  0.345306  -3.881  0.000104 ***
rank4        -1.551464  0.417832  -3.713  0.000205 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 499.98  on 399  degrees of freedom
Residual deviance: 458.52  on 394  degrees of freedom
AIC: 470.52

Number of Fisher Scoring iterations: 4
```

Logistic Regression (로지스틱 회귀분석)

회귀 계수 해석

- **Coefficient** : 회귀계수와 그것들의 표준편차, z-statistics(wals's z-statistics), p-value를 나타낸다. 위 결과에서는 모든 변수가 유의한 것을 알 수 있다. 로지스틱 회귀모형에서는 회귀계수가 변수가 한 단위 증가했을 때 $\log(\text{odds})$ 의 증가량으로 해석할 수 있다
- gre가 1증가할 때, admission의 log odds(non-admission에 대한)가 0.0022 증가한다.

```

Coefficients:
(Intercept) -3.989979 1.139951 z -3.500 0.000465 ***
gre          0.002264 0.001094 z 2.070 0.038465 *
gpa          0.804038 0.331819 z 2.423 0.015388 *
rank2       -0.675443 0.316490 z -2.134 0.032829 *
rank3       -1.340204 0.345306 z -3.881 0.000104 ***
rank4       -1.551464 0.417832 z -3.713 0.000205 ***
  
```

OR(Odds ratio) 과 회귀계수의 관계

앞서 로지스틱 회귀분석에서의 회귀계수는 log odds의 증가량이라고 언급하였다.
그러면 회귀계수에 exponential을 취하면, OR의 증분이 된다.

```

> exp(coef(mylogit))
(Intercept) gre gpa rank2 rank3 rank4
0.0185001 1.0022670 2.2345448 0.5089310 0.2617923
0.2119375
  
```

해석 ex) gpa가 1증가하면 admission의 non-admission에 대한 OR이 2.23배 증가한다.

Logistic Regression (로지스틱 회귀분석)

회귀 계수 해석

- **Coefficient** : 회귀계수와 그것들의 표준편차, z-statistics(wals's z-statistics), p-value를 나타낸다. 위 결과에서는 모든 변수가 유의한 것을 알 수 있다. 로지스틱 회귀모형에서는 회귀계수가 변수가 한 단위 증가했을 때 $\log(\text{odds})$ 의 증가량으로 해석할 수 있다
- gre가 1증가할 때, admission의 log odds(non-admission에 대한)가 0.0022 증가한다.

```

Coefficients:
(Intercept) -3.989979  1.139951 -3.500  0.000465 ***
gre          0.002264  0.001094  2.070  0.038465 *
gpa          0.804038  0.331819  2.423  0.015388 *
rank2       -0.675443  0.316490 -2.134  0.032829 *
rank3       -1.340204  0.345306 -3.881  0.000104 ***
rank4       -1.551464  0.417832 -3.713  0.000205 ***
  
```

- gpu의 경우도 마찬가지로 해석한다.
- 더미변수인 rank의 경우 해석이 약간 다른데, 예를 들어 rank2의 회귀계수 -0.67은 rank1에서 rank2로 바뀌었을 때, $\log(\text{odds})$ 의 변화량이다. 즉, rank1에 비해 rank2가 admission에 안좋은 영향을 준다는 것을 알 수 있다.

48. [단답형] 아래 ()안에 들어갈 용어로 적절한것은?

아래

로지스틱 회귀모형에서 $\exp(\beta_1)$ 의 의미는 $x_1, \dots, x_n$ 이 주어질 때, x_1 이 한 단위 증가할 때마다 성공($y = 1$)의 ()이/가 증가하는지를 나타낸다.

정답입력

오즈(Odds)

26. [데이터 분석] 다음 중 시계열 데이터에 대한 설명으로 가장 부적절한 것은?

- ① 시계열분석의 주목적은 외부인자와 관련해 계절적인 패턴, 추세와 같은 요소를 설명할 수 있는 모델을 결정하는 것이다
- ✓ ② 잡음(noise)은 무작위적인 변동이지만 일반적으로 원인은 알려져 있다
- ③ 짧은 기간 동안의 주기적인 패턴을 계절변동이라 한다
- ④ 시계열 데이터의 모델링은 다른 분석모형과 같이 탐색목적과 예측 목적으로 나눌 수 있다

② 잡음은 무작위적 변동이며 일반적인 원인이 알려져 있지 않다.

24. [데이터 분석] 다음 headsize 데이터는 25개 가구에서 첫 번째와 두 번째 성인 아들의 머리길이(head)와 머리 폭(breadth)을 보여준다. 이에 대한 설명 중 가장 부적절한 것은?

```
아래
> head(headsize)
  head1 breadth1 head2 breadth2
[1,]  191      155  179      145
[2,]  195      149  201      152
[3,]  181      148  185      149
[4,]  183      153  188      149
[5,]  176      144  171      142
[6,]  208      157  192      152

> str(headsize)
num [1:25, 1:4] 191 195 181 183 176 208 189 197 188 192 ...
- attr(*, "dimnames")=List of 2
 ..$ : NULL
  $ : chr [1:4] "head1" "breadth1" "head2" "breadth2"

> out<-princomp(headsize)
> print(summary(out),loadings=TRUE)
Importance of components:

              Comp.1  Comp.2  Comp.3  Comp.4
Standard deviation    15.1    5.42    4.12    3.000
Proportion of Variance  0.8    0.10    0.06    0.032
Cumulative Proportion  0.8    0.91    0.97    1.000

Loadings:
      Comp.1  Comp.2  Comp.3  Comp.4
head1   0.570   0.693  -0.442    0.000
breadth1 0.406   0.219   0.870  -0.173
head2    0.601  -0.633  -0.209  -0.441
breadth2 0.386  -0.267    0.000   0.881
```

- ① 네 개의 주성분을 사용하면 전체 데이터 분산을 모두 설명할 수 있다
- ② 두 번째 주성분은 네 개의 원변수와 양의 상관관계를 가진다
- ③ 주성분분석의 결과를 보여준다.
- ④ 첫 두 개의 주성분으로 전체 데이터 분산의 91%를 설명할 수 있다

Loadings에서 comp.2의 값을 보면 head2와 breadth2는 음의 값을 가짐을 보아 양의 상관관계를 가진다고 할 수 없다.





Section #

주성분 분석(Principal Component Analysis)

주성분 분석(Principal Component Analysis)

• 주성분 분석 예


학생	국어	영어	수학	과학
1	70	87	55	60
2	45	60	78	82
3	90	90	87	88
4	90	89	55	78
....				



주성분 분석(Principal Component Analysis)

• 주성분 분석


- 다수의 변수들이 가지고 있는 전체 변동을 잘 설명할 수 있는 중요한 몇 개의 변수(주성분)들을 새롭게 생성해서 원래의 데이터를 적은 수의 새로운 변수로 요약하는 기법
- 원 데이터가 가지고 있는 복잡한 여러 개의 변수에서 서로 상관관계가 없는 소수의 주성분으로 데이터의 속성을 줄여나간다.



주성분 분석(Principal Component Analysis)

• 주성분 분석


- 다수의 변수들이 가지고 있는 전체 변동을 잘 설명할 수 있는 중요한 몇 개의 변수(주성분)들을 새롭게 생성해서 원래의 데이터를 적은 수의 새로운 변수로 요약하는 기법
- 원 데이터가 가지고 있는 복잡한 여러 개의 변수에서 서로 상관관계가 없는 소수의 주성분으로 데이터의 속성을 줄여나간다.



원자료
2차원 데이터를
1차원으로 압축한다

데이터의 분산이 가장 큰 축을 중심으로

해당 차원에서 그 축을 중심으로 데이터를 모은다
같은 선 상에 있는 데이터들은 겹쳐져 손실된다(압축된다)
이것이 주성분이 된다



만약 3차원을 1차원으로 줄이는 상황이라면
현재 주성분의 직교가 되는 여러 축들 중
분산이 가장 큰 축을 중심으로 위의 작업을 반복한다

주성분 분석(Principal Component Analysis)

주성분 분석은 이러한 특징(특성이 강한=분산 값이 큰)들을 선형 결합시킬 때 데이터들이 가장 다양한 값을 갖도록 하는 특징의 가중치를 찾아 주는 방법이다.

$$\begin{array}{c} \text{개별 데이터} \end{array} \begin{array}{c} \xleftarrow{\text{변수}} \end{array} \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix} \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_p \end{pmatrix} = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}$$


$t_1 \sim t_n$ 이 다양한 값이 나오도록 $\rightarrow$ 분산 값이 최대

주성분 분석의 핵심은 이렇게 찾아진 가중치 w 에 의해 변환된 새로운 값인 $t_1, \dots, t_n$ 이 최대의 분산을 갖도록 w 를 찾는다는 점

주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

• 주성분 분석(Principal Component Analysis) 원리



$$\begin{aligned} t_1 &= x_{11} \cdot w_1 + x_{12} \cdot w_2 + \dots + x_{1p} \cdot w_p \\ t_2 &= x_{21} \cdot w_1 + x_{22} \cdot w_2 + \dots + x_{2p} \cdot w_p \\ &\dots \\ t_n &= x_{n1} \cdot w_1 + x_{n2} \cdot w_2 + \dots + x_{np} \cdot w_p \end{aligned}$$

- p는 변수(특성)의 개수이다.
- 각각의 개별 데이터는 주성분 분석에 의하여 찾아진 각 변수에 대한 가중치를 이용하여 선형 결합된다.

주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

• 주성분 분석(Principal Component Analysis) 원리

```
x1 <-c(26,46,57,36,57,26,58,37,36,56,78,95,88,90,52,56)
x2 <-c(35,74,73,73,62,22,67,34,22,42,65,88,90,85,46,66)
x3 <-c(35,76,38,69,25,25,87,79,36,26,22,36,58,36,25,44)
x4 <-c(45,89,54,55,33,45,67,89,47,36,40,56,68,45,37,56)

score <- cbind(x1,x2,x3,x4)
※ colnames(score) <- c("국어","영어","수학","과학")
rownames(score) <- 1:16
head(score)
  국어 영어 수학 과학
1   26   35   35   45
2   46   74   76   89
3   57   73   38   54
4   36   73   69   55
```

※

```
result <- prcomp(score)
result # 주성분 벡터
Standard deviations (1, .., p=4):
[1] 30.122748 27.052808  9.076140  6.152386

Rotation (n x k) = (4 x 4):
```

	PC1	PC2	PC3	PC4
국어	0.6093268	-0.39286407	-0.6126773	-0.3146508
영어	0.7185749	-0.09337973	0.6200124	0.3008572
수학	0.2624323	0.73573272	0.1052861	-0.6154198
과학	0.2085672	0.54372366	-0.4786711	0.6570680


주성분1 주성분2

주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

※ 주성분 분석(Principal Component Analysis) 실습

- $x_1(\text{vector}), x_2, x_3, x_4 \rightarrow$ 상관관계 $\rightarrow$ 공간좌표계에 시각화(4차원)
- `Row1 <- -(89,78,45,67)`



비율적 거리(상대적거리) = 분산영향을 주기 때문에
 $\rightarrow$ 정규화
 $\rightarrow$ `Prcomp(x, scale=TRUE)`


주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

※ 주성분 분석(Principal Component Analysis) 실습

- x_1 (vector), x_2 , x_3 , x_4 → 상관관계 → 공간좌표계에 시각화(4차원)
- `Row1 <- -(89,78,45,67)`

	PC1	PC2	PC3	PC4
국어	0.6093268	-0.39286407	-0.6126773	-0.3146508
영어	0.7185749	-0.09337973	0.6200124	0.3008572
수학	0.2624323	0.73573272	0.1052861	-0.6154198
과학	0.2085672	0.54372366	-0.4786711	0.6570680
	주성분1	주성분2		



비율적 거리(상대적거리) = 분산영향을 주기 때문에
 → 정규화
 → `Prcomp(x, scale=TRUE)`

주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

※ 주성분 분석(Principal Component Analysis) 실습

```
summary(result) # 요약
```

Importance of components%:

	PC1	PC2	PC3	PC4
Standard deviation	30.1227	27.0528	9.07614	6.15239
Proportion of Variance	0.5157	0.4159	0.04682	0.02151
Cumulative Proportion	0.5157	0.9317	0.97849	1.00000

summary(result)에 의해

- Cumulative Proportion 이 70~80%이상까지 주성분선택
- 주성분 2개(93.17%)선택

result에 의한 주성분 함수

- 주성분1 = $0.61 \times \text{국어} + 0.72 \times \text{영어} + 0.26 \times \text{수학} + 0.21 \times \text{과학}$
- 주성분2 = $-0.39 \times \text{국어} + -0.09 \times \text{영어} + 0.74 \times \text{수학} + 0.54 \times \text{과학}$
- 주성분1=문과성향 / 주성분2=이과성향

주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

• 주성분분석 vs 요인분석

1) 요인분석 (Factor Analysis)

- 등간척도로 측정한 두 개 이상의 변수들에 잠재되어 있는 공통인자를 찾아내는 기법

2) 공통점

- 모두 데이터를 축소하는데 사용

3) 차이점

구분	요인분석	주성분분석
변수의 수	몇 개라고 지정 없이 (2,3,4,5...) 만들 수 있음	제1주성분, 제2주성분, 제3주성분 정도로 활용 (대개 4개 이상은 넘지 않음)
변수이름	요인의 이름을 명명	제1주성분, 제2주성분 등으로 표현
변수 등간의 관계	새 변수들은 기본적으로 대등한 관계를 가짐 어떤것이 중요하더라는 의미가 없음	주성분분석은 제1주성분이 가장 중요하고, 제2주성분이 그다음 중요하게 취급함
분석방법의 의미	목표변수를 고려하지 않고 주어진 데이터에서 변수들을 비슷한 성격들로 묶어서 새로운 잠재변수를 만듦	목표변수를 고려하여 목표변수를 잘 예측/분류하기 위하여 원래 변수들의 선형 결합으로 이루어진 몇개의 주성분들을 찾아냄

주성분 분석(Principal Component Analysis)

• 주성분의 선택법


데이터 분석 > 2장 통계분석

1) 누적 기여율 (cumulative proportion)을 활용한 주성분 선택방법

-주성분분석 결과에서 누적기여율 (cumulative proportion)이 85%이상이면 주성분의 수로 결정할 수 있음

2) scree plot을 활용한 주성분 선택방법

- scree plot을 활용한 고유값(eigenvalue)이 수평을 유지하기 전 단계(-1)로 주성분의 수를 선택함



Importance of components:					
	PC1	PC2	PC3	PC4	PC5
Standard deviation	1.6618	1.2671	0.7420	0.25311	0.13512
Proportion of Variance	0.5523	0.3211	0.1101	0.01281	0.00365
Cumulative	0.5523	0.8734	0.9835	0.99635	1.00000
# 위 표를 보면 PC2에서 누적기여율이 약 87.34%이므로 주성분의 개수는 2개로 설정한다.					

https://en.wikipedia.org/wiki/Scree_plot

38. [데이터 분석] 주성분분석은 차원의 단순화를 통해 서로 상관되어 있는 변수들간의 복잡한 구조를 분석하는 것이 목적이다. 다음중 주성분분석에 대한 설명으로 적절한 것은 무엇인가?

- ①  회귀분석에서 다중공선성 (Multicollinearity) 의 문제를 해결하기 위해 활용한다.
- ② Screen Graph를 이용하는 방법은 고유 값의 크기 순으로 산점도를 그린 그래프에서 감소하는 추세가 원만해지는 지점을 주성분의 개수로 선택한다
- ③ 평균고유값 (average eigenvalue)방법은 고유값들의 평균을 구한 후 고유값이 평균값 이상이 되는 주성분을 제거하는 방법이다
- ④ 변수들이 서로 상관이 있는 경우, 해석상의 복잡한 구조적 문제가 발생하며 이때 변수들 사이의 구조를 쉽게 이해하기 위해 주성분분석이 필요하다

① 주성분분석은 회귀모형 개발시 입력변수들 간의 상관관계가 높은 다중 공선성이 존재할 경우 모형이 잘못 만들어져 문제가 생기므로 이를 해결하기 위해 활용한다.

과목 III 데이터 분석

40. 주성분분석은 p 개의 변수들을 중요한 $m(p)$ 개의 주성분으로 표현하여 전체 변동을 설명하는 방법을 사용한다. 다음 중 주성분 개수(m) 선택 방법에 대한 설명으로 가장 부적절한 것은?

- ① 전체 변이 공헌도(percentage of total variance) 방법은 전체 변이의 70~90% 정도가 되도록 주성분의 수를 결정한다.
- ✓ ② 평균 고윳값(average eigenvalue) 방법은 고윳값들의 평균을 구한 후 고윳값이 평균값 이상이 되는 주성분을 제거하는 방법이다.
- ③ Scree graph를 이용하는 방법은 고윳값의 크기순으로 산점도를 그린 그래프에서 감소하는 추세가 완만해지는 지점에서 1을 뺀 개수를 주성분의 개수로 선택한다.
- ④ 주성분은 주성분을 구성하는 변수들의 계수 구조를 파악하여 적절하게 해석되어야 하며, 명확하게 정의된 해석 방법이 있는 것은 아니다.

② 평균 고윳값 방법은 고유값들의 평균을 구한 후, 고유값이 평균값 이상이 되는 주성분을 제거하는 것이 아니라 설정하는 것이다.

주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

- 주성분분석의 목적

- 여러 변수들간에 내재하는 상관관계, 연관성을 이용해 소수의 주성분으로 **차원을 축소**
- 다중 공선성이 존재하는 경우 상관성이 없는 주성분으로 변수를 축소
- 회귀분석이나 의사결정나무(Decision Tree)등의 모형 개발 시 입력변수들간의 상관관계가 높은 다중공선성이 존재할 경우 모형이 잘 못 만들어질 수 있음



주성분 분석(Principal Component Analysis)

데이터 분석 > 2장 통계분석

• 주성분분석 vs 요인분석

1) 요인분석 (Factor Analysis)

- 등간 척도로 측정한 두 개 이상의 변수들에 잠재되어 있는 공통인자를 찾아내는 기법

2) 공통점

- 모두 데이터를 축소하는데 사용

3) 차이점

구분	요인분석	주성분분석
변수의 수	몇 개라고 지정 없이 (2,3,4,5...) 만들 수 있음	제1주성분, 제2주성분, 제3주성분 정도로 활용 (대개 4개 이상은 넘지 않음)
변수이름	요인의 이름을 명명	제1주성분, 제2주성분 등으로 표현
변수 등간의 관계	새 변수들은 기본적으로 대등한 관계를 가짐 어떤것이 중요하다는 의미가 없음	주성분분석은 제1주성분이 가장 중요하고, 제2주성분이 그다음 중요하게 취급함
분석방법의 의미	목표변수를 고려하지 않고 주어진 데이터에서 변수들을 비슷한 성격들로 묶어서 새로운 잠재변수를 만듦	목표변수를 고려하여 목표변수를 잘 예측/분류하기 위하여 원래 변수들의 선형 결합으로 이루어진 몇개의 주성분들을 찾아냄

과목 III 데이터 분석

9. 아래는 주성분분석을 수행한 결과이다. 첫번째 분산은 전체 분산의 몇 %를 설명하고 있는가?
 (소수점 첫째자리까지 표시하시오.)


	Comp.1	Comp.2	Comp.3	Comp.4
Standard deviation	1.5574873	0.9943214	0.5943221	0.4123679
Proportion of Variance	0.5748331	0.2321003	0.1834561	0.0096105
Cumulative Proportion	0.5748331	0.8069334	0.9903895	1.0000000

[정답] 첫번째 분산(Proportion of Variance)은 0.5748331 이므로 대략 **57.5%**의 설명력을 갖는다.

Naive Bayesian

• 베이즈 정리(Bayes's Theorem)

$P(A)$ 가 A가 일어날 확률, $P(B)$ 가 B가 일어날 확률, $P(B|A)$ 가 A가 일어나고 나서 B가 일어날 확률, $P(A|B)$ 가 B가 일어나고 나서 A가 일어날 확률이라고 하자. 이때 $P(B|A)$ 를 쉽게 구할 수 있는 상황이라면, 아래와 같은 식을 통해 $P(A|B)$ 를 구할 수 있다.



Law of total Probability

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Diagram labels for the equation above:

- $P(A|B)$: 사후확률 (Posterior Probability)
- $P(B|A)$: 가능도 (Likelihood)
- $P(A)$: 사전확률 (Prior Probability)
- $P(B)$: 증거 (Evidence)



$P(\text{정상 메일} | \text{'반짝'}) = \text{입력 텍스트('반짝')가 있을 때 정상 메일일 확률}$
 $P(\text{스팸 메일} | \text{'반짝'}) = \text{입력 텍스트('반짝')가 있을 때 스팸 메일일 확률}$

이를 베이즈의 정리에 따라서 식을 표현하면 이와 같다.

$P(\text{정상 메일} | \text{'반짝'}) = (P(\text{'반짝'} | \text{정상 메일}) \times P(\text{정상 메일})) / P(\text{'반짝'})$

$P(\text{스팸 메일} | \text{'반짝'}) = (P(\text{'반짝'} | \text{스팸 메일}) \times P(\text{스팸 메일})) / P(\text{'반짝'})$

Naive Bayesian

- **베이즈 정리(Bayes's Theorem)**

- 입력 텍스트가 주어졌을 때, $P(\text{정상 메일} \mid \text{입력 텍스트})$ 가 $P(\text{스팸 메일} \mid \text{입력 텍스트})$ 보다 크다면 정상 메일이라고 볼 수 있으며, 그 반대라면 스팸 메일이라고 볼 수 있다. 그런데 두 확률 모두 식을 보면 $P(\text{입력 텍스트})$ 를 분모로 하고 있음을 알 수 있다. 그렇기 때문에 분모를 양쪽에서 제거하여 식을 간소화한다.

$$P(\text{정상 메일} \mid \text{입력 텍스트}) = P(\text{입력 텍스트} \mid \text{정상 메일}) \times P(\text{정상 메일})$$

$$P(\text{스팸 메일} \mid \text{입력 텍스트}) = P(\text{입력 텍스트} \mid \text{스팸 메일}) \times P(\text{스팸 메일})$$

- **나이브 베이즈 정리(Naive Bayes's Theorem)**

- 나이브 베이지안에서 나이브(Naive)는 “순진하다”라는 뜻을 가지고 있다. 이런 수식어가 붙은 이유는 데이터셋의 모든 특징들이 동등하고 독립적이라고 가정하기 때문이다. 예를 들어 비가 오는 날에는 시간보다는 습도가 더 중요한 변수가 될 수 있지만 나이브 베이지안에서는 이런 사실을 무시하기 때문이다. 하지만 이런 가정에도 불구하고 분류학습에서 매우 정확한 결과 값을 내놓기 때문에 자주 사용되고 있다.
- **가능도($P(B|A)$)을 순수하게 구해서 사용하기 때문에 나이브 베이지안라고 한다.**

Naive Bayes

• 나이브 베이즈 확률 계산 예제

Q. 스팸 메일 3개를 포함한 전체 이메일 10개 중, "free"라는 단어가 들어간 메일이 4개 이고, 스팸 메일 중 "free"가 2/3 확률로 들어가 있을 때, "free"가 들어간 이메일이 스팸 메일일 확률은?

A. $P(\text{spam})=0.3$, $P(\text{free})=0.4$, $P(\text{'free'}|\text{spam})=2/3$ 일때,
 $P(\text{spam}|\text{'free'}) = 0.3 \cdot 0.4 / (2/3) = 0.5$

Q. 상자 A(파란공 1개, 빨간공 2개), 상자 B (파란공 2개, 빨간공 1개)가 있다. 상자 A와 B 중 한 상자에서 공 1개를 뽑았을 때, 빨간색 공이면 그 공이 상자 A에서 나왔을 확률은?

A. $P(A)=P(B)=0.5$, $P(\text{'red'}|A)=2/3$, $P(\text{'red'})=0.5$ 일때,
 $P(A|\text{'red'}) = P(\text{'red'}) \cdot P(\text{'red'}|A) / P(A) = 0.5 \cdot (2/3) / 0.5 = 2/3$

Section #

의사결정트리

의사결정나무

- 정의: 분류 함수를 의사결정 규칙으로 이뤄진 나무 모양으로 그리는 방법으로, 의사결정 문제를 시각화해 의사결정이 이뤄지는 시점과 성과를 한눈에 볼 수 있다.
- 분석 과정:
 - ① 성장단계 : **최적의 분리규칙을 찾음**
 - ② 가지치기(Pruning)단계 : **오차를 크게 할 위험이 높거나 불필요한 가지 제거**
 - ③ 타당성 평가 단계 : 이익도표, 위험도표, 시험자료를 이용하여 의사결정나무 평가
 - ④ 해석 및 예측 단계 : 나무모형 해석 및 예측모형을 설정 후 예측에 적용
- 최적의 분리 규칙 기준 : **최적 분할의 결정은 불순도 감소량을 가장 크게 하는 분할**

$$Gini(T) = 1 - \sum_{l=1}^k p_l^2$$

(Diagram annotations: A green arrow points from the text "확률" (Probability) to the term p_l^2 . A red arrow points from the text "전체 완전 불순" (Total complete impurity) to the entire expression. Another red arrow points from the text "어느 정도 일치하는가?" (How much do they agree?) to the summation part of the formula.)

의사결정나무

- 다양한 최적의 분리 규칙 알고리즘

p. 403 ~

- 이산형 목표변수

기준값	분리기준
카이제곱 통계량 p값	P값이 가장 작은 예측변수와 그 때의 최적분리에 의해서 자식마디를 형성
지니 지수	지니 지수를 감소시켜주는 예측변수와 그 때의 최적분리에 의해서 자식마디를 선택
엔트로피 지수	엔트로피 지수가 가장 작은 예측 변수와 이 때의 최적분리에 의해 자식마디를 형성


$$\chi^2 = \sum_{i=1}^k \frac{(O_i - B_i)^2}{B_i} \quad (k : \text{범주의 수}, O_i : \text{실제도수}, B_i : \text{기대도수})$$

$$Gini(T) = 1 - \sum_{l=1}^k p_l^2$$

$$Entropy(T) = - \left(\sum_{l=1}^k p_l \log_2 p_l \right)$$

- 연속형 목표변수

기준값	분리기준
분산분석에서 F 통계량	P값이 가장 작은 예측변수와 그 때의 최적분리에 의해서 자식마디를 형성
분산의 감소량	분산의 감소량을 최대화 하는 기준의 최적분리에 의해서 자식마디를 형성



의사결정나무

- 불순도 측정

 p. 403 ~

- 의사결정트리 학습에서 각 노드에서 분기하기 위한 최적의 질문은 정보이득(information Gain)이라는 값이 최대가 되도록 만들어주는 것이 핵심이다. 어느 특정 노드에서 m 개의 자식 노드로 분기되는 경우 정보이득은 아래의 식으로 정의한다.


$$IG(D_p, f) = \overbrace{I(D_p)}^{\text{부모 노드의 데이터 불순도}} - \underbrace{\sum_{j=1}^m \frac{N_j}{N_p} I(D_j)}_{\text{자식 노드의 데이터 불순도의 합}}$$

여기서, f 는 분기를 시키기 위한 트레이닝 데이터의 특성값(예를 들어, 꽃잎 길이 또는 꽃잎 너비)이며 D_p 는 부모 노드에 존재하는 데이터 세트, D_j 는 j 번째 자식노드에 존재하는 데이터 세트입니다. $I(D_p)$ 는 D_p 의 데이터 불순도 (impurity), $I(D_j)$ 는 D_j 의 데이터 불순도를 의미합니다. 그리고 N_p 와 N_j 는 D_p 의 데이터 개수와 D_j 의 데이터의 개수입니다.

의사결정나무

- 의사결정분석 알고리즘의 종류

p. 403 ~



알고리즘	분리기준(목표변수)	비고
ID3	Entropy	다지분리(범주)
C4.5	Information Gain	다지분리(범주) 및 2진분리(연속)
C5.0	Information Gain	C4.5와 거의 유사
CHAID	카이제곱(범주), F검정(연속)	통계적 접근 방식
CART	Gini Index(범주), 분산의 차이(연속)	통계적 접근 방식, 항상 2진 분리

*: 활용도가 높은 알고리즘

의사결정나무

- 의사결정분석의 장단점


p. 403 ~

장점	단점
- 설명력이 높다. - 결과에 대한 근거를 나뉘어 가지 형태로 추적할 수 있다. - 빠르고 변수 선택 능력이 있다. - 많은 변수들을 대상으로 종속변수에 영향이 높은 변수를 선택 할 수 있다.	- 종속변수가 연속형일 때 쓸 수 없다. - 설명변수가 연속형일 때 낮은 예측능력을 보일 수 있다. - 자료의 추가에 의하여 나무구조가 바뀔 수 있다. - 비선형데이터에는 적합하지 못하다.

- 모델의 시각화가 쉽고, 가독성이 높다
- 변수의 표준화 작업(scale)이 필요 없다.
- 과대적합을 해결해야 한다.

***너무 쪼개지는 걸 막기 위해 각 규칙이 포함된 관측 값의 최소 갯수를 제한해야 한다(minsplit)**

- * 가지치기를 통해 불필요한 판별기준을 없앤다
- (단점) 단일결정 tree는 과대적합이 발생하여 일반화 성능이 저하된다.
 통계적 유의성에 대한 판단없이 노드를 분할한다
 다양한 값으로 분할 가능한 변수가 다른 변수에 비해 선호되는 문제를 갖고 있다.

Section #

앙상블

과목 III 데이터 분석

23. 붓스트랩 표본을 구성하는 재표본 과정에서 분류가 잘못된 데이터에 더 큰 가중치를 주어 표본을 추출하는 기법을 무엇이라고 하는가?

① 배깅(Bagging)

③ 랜덤포레스트(Random Forest)



② 부스팅(Boosting)

④ 시그모이드


② 부스팅은 붓스트랩 표본을 구성하는 재표본 과정에서 분류가 잘못된 데이터에 더 큰 가중치를 주어 표본을 추출하는 기법/ 예측력이 약한 모형들을 결합하여 강한 예측모형을 만드는 방법이다.

앙상블 기법

1. 앙상블 기법이란

- 강력한 하나의 모델을 사용하는 대신 보다 약한 모델 여러 개를 조합하여 더 강력한 예측 모형 생성
- 현실세계로 예를 들면, 어려운 문제를 해결하는데 한 명의 전문가보다 여러 명의 집단지성을 이용하여 문제를 해결하는 방식

p. 403 ~




앙상블

2. 앙상블 기법의 종류

1) 배깅 (Bagging)

-여러 개의 Bootstrap(부트스트랩) 자료를 생성하고 각 부트스트랩 자료에 예측 모델을 만든 후 결합하여 최종 예측 모델을 만들

-부트스트랩은 Random Sampling (복원추출)을 통해 표본을 여러 개 생성하는 샘플링 방법으로 100개의 샘플을 추출하더라도 한번도 선택되지 않은 원 데이터가 발생할 수 있으며 전체 샘플의 약 36.8% 가 이에 해당함



< 배깅 알고리즘 >

p. 403 ~


앙상블

2. 앙상블 기법의 종류


2) 부스팅 (Boosting)

- 예측력이 약한 모형들을 선형으로 결합하여 강한 예측모형을 만드는 방법
- 배경에 비해 많은 경우 예측오차가 향상되어 부스팅의 성능이 배경보다 뛰어난 경우가 많음

p. 403 ~



<부스팅 알고리즘>





<Adaboost>

앙상블

2. 앙상블 기법의 종류

• 배깅과 부스팅 (Boosting)

- 배깅은 데이터로부터 동일한 크기의 랜덤 샘플 자료를 이용하여 학습시키는 방법이라면 부스팅은 배깅과 마찬가지로 시작을 하지만 잘 맞춘 경우에는 가중치를 낮추고 정답을 틀린 경우에는 가중치를 높여서 전체적으로 성능향상을 기대하는 방법이라고 볼 수 있다.




앙상블

2. 앙상블 기법의 종류

3) Random Forest

- 배깅과 부스팅보다 더 많은 무작위성을 주어 **약한 학습기들을 선형 결합하여 최종 학습기를 만들어냄**

p. 403 ~



앙상블

2. 앙상블 기법의 종류

3) Random Forest

• randomForest를 이용한 모델링

- 랜덤 포레스트는 여러 개의 의사 결정 나무로 구현되고, 각 의사 결정 나무는 데이터의 일부만 사용한다. 랜덤 포레스트 모델을 출력하면 모델 훈련에 사용되지 않은 데이터(Bootstrap 샘플링 과정에서 추출되지 않은 데이터)를 사용한 에러 추정치가 '**OOB(Out of Bag) estimate of error rate**' 항목으로 출력된다. 아이리스에 대한 모델에서는 OOB 에러가 4%였으며, versicolor가 virginica로 예측된 경우가 3개, virginica가 versicolor로 예측된 경우가 3개 있었다.

평가용 데이터에서의 오분류율을 예측하는 용도 및 변수 중요도를 추정하는 용도로 많이 이용

p. 403 ~

실측치

```
> rf<-randomForest(Species~.,data=iris)
> rf

Call:
randomForest(formula = Species ~ ., data = iris)
      Type of random forest: classification
      Number of trees: 500
No. of variables tried at each split: 2

      OOB estimate of error rate: 4%
Confusion matrix:
      setosa versicolor virginica class.error
setosa      50         0         0         0.00
versicolor   0        47         3         0.06
virginica     0         3        47         0.06
```

"평가용(test) 데이터가 4%정도의 오분류를 낼 것이라고 예측한다라는 의미"

예측치

앙상블

2. 앙상블 기법의 종류

3) Random Forest

• 변수의 중요도 평가

다수의 의사 결정 나무로부터 변수가 정확도와 노드 불순도 개선에 기여하는 측면을 측정하므로 평균(Mean)이 언급되어 있다.

#변수의 중요도 평가

```
> rf3<-randomForest(Species~.,data=iris, importance=TRUE)
> importance(rf3)
```

```
> importance(rf3)
```

	setosa	versicolor	virginica	MeanDecreaseAccuracy
sepal.Length	5.701070	8.155737	8.256003	11.292997
sepal.width	4.378275	1.146595	4.510524	5.098796
Petal.Length	22.174380	34.340750	27.313261	33.575678
Petal.width	21.780201	31.695396	32.055697	33.100096

	MeanDecreaseGini
sepal.Length	9.520747
sepal.width	2.145927
Petal.Length	43.425924
Petal.width	44.164295

정확도에서는 Petal.Length → ... → Sepal.Width 순으로 변수가 중요하다고 판단

MeanDecreaseGini(노드 불순도 개선)

: 이 계수에서는 Petal.Width → Petal.Length → Sepal.Length → Sepal.Width 순으로 중요

Section #

인공신경망

23회 기출

18. [데이터 분석] 다층 신경망은 여러개의 은닉층(hidden layer)을 가질 수 있는 데, 다음 중 은닉층 노드의 수가 너무 적을 경우 나타나는 특징을 설명한 것으로 가장 적절한 것은?


- ① 오차의 역전파 알고리즘에서 기울기 소실 문제가 발생한다
- ✓ ② 네트워크가 복잡한 의사결정 경계를 만들 수 없다.
- ③ 네트워크의 일반화가 어렵다.
- ④ 훈련에 많은 시간이 소요된다.

② 은닉층의 노드의 수는 너무 적으면 네트워크의 복잡한 의사결정 경계를 만들 수 없으며, 너무 많으면 네트워크의 일반화가 어렵다.

인공신경망(Artificial Neural Network Theory) 모델

• 인공신경망


- 인간의 뇌를 기반으로 한 추론 모델이다.
- 뉴런은 기본적인 정보 처리 단위이다.



인공신경망(Artificial Neural Network Theory) 모델


• 단층(Layer) 퍼셉트론

중간층(hidden layer) 이 없는 신경망 모델



인공신경망(Artificial Neural Network Theory) 모델



- 확률적 경사하강법



$$\mathbf{W} \leftarrow \mathbf{W} - \eta \frac{\partial L}{\partial \mathbf{W}}$$

인공신경망(Artificial Neural Network Theory) 모델

- 다층 퍼셉트론의 필요성




비선형분포 문제를 해결할 수 없다.


인공신경망(Artificial Neural Network Theory) 모델

- 다층 퍼셉트론의 필요성

- 단층 퍼셉트론으로 풀 수 없던 문제를 XOR 문제를 풀 수 있다.




Layer 의 개수에 따라 결정할 수 있는 영역



인공신경망(Artificial Neural Network Theory) 모델

• 역전파 알고리즘

순전파(feedforward) : 다층 퍼셉트론에서는 입력층에서 전달되는 값이 은닉층의 모든 노드로 전달되며 은닉층의 모든 노드의 출력값 역시 출력층의 모든 노드로 전달된다. → 루프를 돌지 않으면서 각 층의 출력값이 그 다음 층의 입력값이 된다는 의미이다.



.....


먼저 $w_{10}^{(1)}$ 을 학습시키자

$$\frac{\partial E_{tot}}{\partial w_{10}^{(1)}} = \frac{\partial E_{tot}}{\partial a_{20}} \frac{\partial a_{20}}{\partial z_{20}} \frac{\partial z_{20}}{\partial w_{10}^{(1)}}$$

• 기울기 소실(Gradient Vanishing)

- 층이 깊어질 수록 기울값이 소실되어(W=0) 비용함수가 정확한 w를 찾지 못하는 일이 발생

인공신경망(Artificial Neural Network Theory) 모델



기출문제

12회 기출

단층신경망인 퍼셉트론(perceptron)에서 최종 목표값(Target value)은 활성화함수에 의해 결정되는데 다양한 활성화함수 중 출력값이 여러 개로 주어지고, 목표치가 다범주인 경우 각 범주에 속할 사후확률을 제공하는 함수는 무엇인가?

- ① Tanh 함수 ② Gauss 함수 ③ Sigmoid 함수 ☒ Softmax 함수

인공신경망(Artificial Neural Network Theory) 모델

신경망 층을 깊게 하는데 의미가 없다. $\rightarrow c*c*c*x = y$

• 뉴런의 활성화 함수

1) 시그모이드 함수

- 로지스틱 회귀분석과 유사하며 0~1의 확률 값을 가짐 ($0 \leq y \leq 1$)
- 활성화 함수

2) Softmax 함수 (표준화지수 함수)

- 출력값이 여러개이며 각 출력별 확률 제공
- 소프트맥스는 인풋값을 여러개 갖는 일종의 함수로, 확률처럼 모든 아웃풋 값을 더했을 때 1이 총합이라는 특징이 있습니다.


3) Relu 함수

- 입력값이 0 이하는 0, 0 이상은 x값을 가지는 함수


4) 은닉층(Hidden Layer)과 은닉노드(Hidden Node)의 수

- 은닉층/노드가 많으면 가중치가 많아져 과적합 문제 발생
- 은닉층/노드가 적으면 신경망에서 조정이 더 이상 힘든 과소적합 발생 > 포화문제
- 은닉층/노드가 적으면 복잡한 의사결정 경계를 만들 수 없음
- 은닉노드의 수는 적절히 큰 값으로 두고 가중치를 감소 시키며 적용하는 것이 좋음
- 은닉층은 가능한 하나로 선정함

선형함수



비선형함수



Section #

K-최근접 이웃(K-Nearest Neighbor) 기법

K-최근접 이웃(K-Nearest Neighbor) 기법

- K-최근접 이웃 기법은 목표변수의 범주를 알지 못하는 데이터 세트의 분류를 위해 해당데이터 세트와 가장 유사한 주변 데이터 세트의 범주로 지정하는 방식으로 분류예측을 하는 기법이다. 이러한 K-최근접 이웃 기법에서는 해당 데이터 점과 주변 데이터 세트 간의 '유사성'을 어떻게 측정할 것인가와 최종적으로 목표변수의 범주를 분류할 때 주변 데이터 세트 몇 개를 기준으로 판단할 것인가에 대한 기준이 필요하다.

① 유사성 측정 방법

일반적으로 두 점 간의 유클리디안 제곱 거리의 역수를 취하거나 피어슨 상관계수를 이용하여 유사성을 계산한다. 점들이 이산형 변수일 경우 자카드 계수(Jaccard coefficient)를 사용한다.


② 목표변수 분류 기준

K-최근접 이웃에서의 'K'는 해당 데이터 점과 주변 데이터 세트 간의 유사성을 측정한 후, 해당 데이터 점의 목표변수 분류를 위해 참조할 주변 데이터 점들의 개수를 의미한다. 예를 들어 어떤 고객이 좋아하는 영화와 유사하면서 기존에 시청하지 않았던 영화에 대한 추천을 생각해볼 수 있다. 이럴 때 해당 고객이 좋아하는 영화와 가장 유사한 영화 1개만 고려한다면 '1-근접이웃'이라고 말할 수 있고, 유사한 영화 3개 를 고려한다면 '3-근접이웃'이라고 말할 수 있다. 이런 식으로 해당 데이터 점과 유사한 k개의 주변 데이터 점을 살펴보고, 해당 데이터 점의 분류범주를 고려하여 다수결의 원칙에 따라 새로운 범주를 결정하는 방식이 K-근접이웃 기법이다

K-최근접 이웃(K-Nearest Neighbor) 기법

- K-최근접 이웃

② 목표변수 분류 기준



K-최근접 이웃 기법에서의 K 값 변화에 따른 목표변수 범주 변화

'☆'으로 표시된 점이 새롭게 분류해야 할 데이터 값이고 나머지 '□'와 '○'로 표시된 점들은 주변에 존재하는 다른 데이터 점이다. 여기서 $K=1$ 로 설정하면, '☆'와 가장 가까운 데이터 점은 '○'이므로 '☆'의 목표변수는 '○'로 분류될 것이다. 반면 $K=3$ 으로 설정하면 '☆'와 가장 가까운 3개의 점을 고려하게 되므로 '□'가 2개, '○'가 1개이므로 이때는 '☆'점은 '□'로 분류되게 된다. 한편 $K=5$ 로 설정한다면, '☆'주변에 '○'가 더 많으므로, 다수결의 원칙에 의하여 또다시 '○'로 분류될 것이다. 여기서 우리가 알 수 있는 것은 K-최근접 이웃 기법에서는 K 값을 어떻게 정하느냐에 따라 목표변수의 범주 예측 결과가 크게 달라질 수 있다는 점이다. 따라서 K-최근접 이웃 기법에서는 적절한 K 값을 정하는 것이 중요하다.

K-최근접 이웃(K-Nearest Neighbor) 기법

- K-최근접 이웃

③ K-최근접 이웃 기법의 장/단점

장점	단점
• 알고리즘 이해가 쉽고 직관적이다. • 사전 모형 설정 및 모수 추정이 필요 없다. • 데이터 세트의 확률분포 등에 대한 가정이 필요 없다. • 빠른 훈련(학습) 시간	• 모형이 없으므로, 변수들간의 관계 등 가설검증이나 구조 등에 대한 분석을 통해 통찰력을 얻기 어렵다. (특정한 가설이나 모형 없이 주어진 데이터를 통해 범주의 분류결과만 판단) • k에 대한 명확한 기준 없으며 시행착오적 접근 필요 • 느린 분류(예측) 소요시간 (새로운 데이터가 주어질 때마다 모든 데이터와의 유사성 계산해야 하므로 그만큼 시간 소요. 이런 특성으로 인해 게으른 학습(Lazy Learning)으로 불림) • 많은 메모리 소요(대용량 데이터일 때 불리함)

Section #


군집화(Clustering)

37. [데이터 분석] 다음 중 계층적 군집방법이 아닌 것은?

- ✓ ① K-means 연결법
- ② 평균연결법
- ③ 중심연결법
- ④ 최단연결법

① k-means 연결법은 비계층적 군집방법이다.

47. [단답형] 아래는 미국 50개 주의 범죄유형으로 군집 분석을 한 결과이다. Height = 60에 서 아래의 덴드로그램을 통해 군집 결과를 도출하면 총 군집의 수는 몇개인가




정답입력

3 개

3개의 군집 → 군집내의 거리 값을 의미하는 y축이 크게 차이 없이 만들어주는 군집의 갯수


군집화 vs 분류 목적

- 일련의 관측값 들을 적절한 기준으로 서로 유사한 관측값끼리 그룹으로 묶는(군집화) 기법을 의미하며, 군집화는 사전에 그룹이 어떤 형태인지 모르는 상태에서 실행하게 된다.
- **분류목적의 머신러닝에서는 목적변수(Y)의 라벨이 주어진 상태**에서 해당 목적변수의 범주 속성으로 분류되는 개체를 유사성이 나 다른 기준으로 판별하는 것이 목적이었다면, **군집분석은 목적변수가 없는 상태에서 유사한 특성을 가진 개체끼리 그룹화**를 한다는 점이 다르다.



군집화(cluster analysis)


• 군집분석의 종류




계층적 군집화(cluster analysis)

• 계층적 군집을 형성하는 방법


- ① 병합적(agglomerative) 방법 : 작은 군집 → 군집을 병합해 가는 방법
- ② 분할적(divisive) 방법 : 큰 군집 → 군집을 분리해 가는 방법



<병합적 방법을 적용한 계층적 군집>



<덴드로그램 형태의 계층적 군집>



계층적 군집화

- ‘계층적 군집화’란 계층적 트리 모형을 개발해 개별 개체들을 순차적, 계층적으로 유사한 개체 또는 그룹과 통합하여 군집화를 수행하는 알고리즘이다.
- 개체들이 결합되는 순서를 나타내는 트리 형태의 구조인 덴드로그램(Dendrogram)을 사용한다.

덴드로그램

개체간에 계층적 관계를 보여주는 다이어그램이다.

덴드로그램 해석의 핵심은 두 물체가 결합된 높이에 초점을 맞추는 것이다. 위의 예에서 A와 B, D와 E는 서로 연결되는 링크의 높이가 가장 작기 때문에 각각의 둘이 가장 유사하다는 것을 알 수 있다.

최단연결법 single linkage method	두 군집 사이의 거리를 각 군집에서 하나씩 관측값을 뽑았을 때 나타날 수 있는 거리의 최소값으로 측정 최단거리를 사용할 때 사슬 모양으로 생길 수 있으며 고립된 군집을 찾는데 중점을 둔 방법
최장연결법 complete linkage method	두 군집 사이의 거리를 각 군집에서 하나씩 관측 값을 뽑았을 때 나타날 수 있는 거리의 최대값으로 측정 같은 군집에 속하는 관측치는 알려진 최대 거리보다 짧으며 군집들의 내부 응집성에 중점을 둔 방법
중심연결법	두 군집의 중심 간의 거리를 측정한다. 두 군집이 결합될 때 새로운 군집의 평균은 가중평균을 통해 구해진다.
평균연결법	모든 항목에 대한 거리 평균을 구하면서 군집화를 하기 때문에 계산량이 불필요하게 많아질 수 있다.
와드연결법	군집내의 오차 제곱합에 기초하여 군집을 수행한다. 보통 두 군집이 합해지면 병합된 군집의 오차 제곱합은 병합 이전 각 군집의 오차제곱합의 합보다 커지게 되는데 그 증가량이 가장 작아지는 방향으로 군집을 형성해 나가는 방법이다.

계층적 군집화(cluster analysis)

- 연속형 변수일 경우 거리 구하는 방법

수학적 거리

유클리드 (Euclidian) 거리 $d(i, j) = \sqrt{\sum_{f=1}^p (x_{if} - x_{jf})^2}$

맨하튼 거리 or 시가 (city - block) 거리 $d(i, j) = \sum_{f=1}^p |x_{if} - x_{jf}|$

민코우스키거리 $d(i, j) = \left[\sum_{f=1}^p (x_{if} - x_{jf})^m \right]^{\frac{1}{m}}$

통계적 거리

표준화거리 $d(i, j) = \sqrt{(x_i - x_j)' D^{-1} (x_i - x_j)}$,

$D = \text{Diag}(S_{11}, \dots, S_{pp})$: 표본분산 (대각) 행렬

마할라노비스 거리 $d(i, j) = \sqrt{(x_i - x_j)' S^{-1} (x_i - x_j)}$,

$S = (S_{ij})_{p \times p}$: 표본 공분산행렬

표준화 거리는 변수의 측정단위를 표준화한 거리이며, 마할라노비스 거리는 변수의 표준화와 함께 변수 간의 상관성을 동시에 고려한 통계적 거리로 생각할 수 있다.


계층적 군집화(cluster analysis)

- y축이 두 클러스터가 합쳐질 때를 보여주는 것뿐만 아니라 y 축 가지의 길이는 클러스터가 얼마나 멀리 떨어져 있는지 보여준다. 이 덴드로그램에서 가장 긴 가지는 세 개 클러스터로 표시한 점선이 가로지르는 세 개의 수직선이다.
- 이 가지가 가장 길다는 것은 클러스터가 세 개에서 두 개로 될 때 꽤 먼 거리의 포인트들을 모은다는 뜻이다.
- 즉 (5, 0, 11)로 이뤄진 클러스터와 (10, 7, 6, 9)로 이뤄진 클러스터가 합쳐질 때 먼 거리의 포인트들이 한 클러스터로 묶이게 된다는 뜻이다.

y축이 두 클러스터가 합쳐질 때를 보여주는 것뿐만 아니라 y 축 가지의 길이는 클러스터가 얼마나 멀리 떨어져 있는지 보여준다. 이 덴드로그램에서 가장 긴 가지는 세 개 클러스터로 표시한 점선이 가로지르는 세 개의 수직선이다.

이 가지가 가장 길다는 것은 클러스터가 세 개에서 두 개로 될 때 꽤 먼 거리의 포인트들을 모은다는 뜻이다.

즉 (5, 0, 11)로 이뤄진 클러스터와 (10, 7, 6, 9)로 이뤄진 클러스터가 합쳐질 때 먼 거리의 포인트들이 한 클러스터로 묶이게 된다는 뜻이다



계층적 군집화(cluster analysis)

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_iris
from scipy.cluster.hierarchy import dendrogram, linkage


# 1. 데이터 준비 (iris 데이터셋의 특성 데이터만 사용)
iris = load_iris()
X = iris.data

# 시각화를 간단히 하기 위해 데이터 일부(상위 30개)만 추출
X_sample = X[:30]

# 2. 계층적 군집화 수행 (Ward 연결법 적용)
# linkage 함수는 데이터 X_sample에 대한 계층적 군집화 수행 결과를 반환함
linked = linkage(X_sample, method='ward')

# 3. 덴드로그램 시각화
plt.figure(figsize=(10, 7))
dendrogram(linked,
            orientation='top',
            distance_sort='descending',
            show_leaf_counts=True)

plt.title('Hierarchical Clustering Dendrogram (Iris Subset)')
plt.xlabel('Sample Index')
plt.ylabel('Distance')
plt.show()
```



23. [데이터 분석] 아래 데이터셋 A, B 간의 유사성을 맨하튼(Mahattan)거리로 계산하면 얼마인가?

아래

	키	몸무게
A	165	65
B	170	70



10

② 15


③ 20

④ 25

① A,B간의 유사성을 맨하튼 거리로 표현하면 $d(x,y) = \sum_{i=1}^p |x_i - y_i| = |165 - 170| + |65 - 70| = 10$

맨하탄의 거리

파란색과 노란색과 붉은색 선들은 모두 총길이가 같다는 함정이 있다. 이것이 바로 맨하탄 거리이다. 맨하탄 거리는 왼쪽 아래의 좌표를 (x_1, y_1) 이라 하고, 우측 상단의 좌표를 (x_2, y_2) 라고 할 때, 맨하탄 좌표의 공식을 적어보면 다음과 같다. $|x_1 - x_2| + |y_1 - y_2|$



초록선: 유클리디언 거리, 그 외의 선: 맨하탄 거리

$B(a_2, b_2)$ 이 알고리즘을 3차원으로 확장하면 다음과 같다.


$$|x_1 - x_2| + |y_1 - y_2| + |z_1 - z_2|$$

결국 맨하탄 거리의 최종 공식은 다음과 같은 모습으로 표현될 수 있을 것이다.

$$d(A, B) = \sum_{i=1}^n |a_i - b_i|$$


유클리디안의 거리 vs 맨하탄의 거리

유클리드 거리



$$d = \sqrt{(a'_1 - a_1)^2 + (a'_2 - a_2)^2}$$

맨하튼 거리



$$d = (a'_1 - a_1) + (a'_2 - a_2)$$

군집분석

• 비계층적 군집분석


1) k-평균 군집분석 (k-means clustering)

- 주어진 데이터를 k개의 클러스터로 묶는 알고리즘으로 각 클러스터와의 거리 차이의 분산을 최소화하는 방식으로 동작


2) k-평균 군집분석 절차

- ① 초기 군집으로 k개 임의 설정
- ② 각 자료의 가까운 군집 할당
- ③ 각 군집의 평균으로 중심 이동
- ④ 군집 중심이 변화 없을 때까지 반복


(가) 임의의 초기 군집 중심 설정




(나) 중심점과의 거리 계산 및 군집 할당



(다) 각 군집의 새로운 중심점 계산 및 이동




(라) 각 관측치들을 새로운 군집에 재할당



군집분석

- 비계층적 군집분석

Scree plot 에서 변화가 급격하게 줄어드는 지점을 찾는다.



Cf) PCA분석 후, Scree plot을 활용하여 고유값(eigenvalue)이 수평을 유지하기 전 단계로 주성분의 수를 선택

28. [데이터 분석] 소매점에서 물건을 배열하거나 카탈로그 및 교차 판매 등에 적용하기 적합한 데이터마이닝 기법은 무엇인가?



- ① 연관분석 (Association analysis)
- ② 예측 (Prediction)
- ③ 분류 (Classification)
- ④ 군집 (Clustering)

① 연관분석은 실시간 상품추천을 통한 교차판매 등에 활용할 수 있다.

29. [데이터 분석] 도출된 연관 규칙이 얼마나 유의미한지 평가하기 위한 지표 중 아래 설명이 가리키는 지표로 가장 적절한 것은?

아래

품목 B를 구매한 고객 대비 품목 A를 구매한 후 품목 B를 구매하는 고객에 대한 확률을 의미하며 만일 이 지표의 값이 1보다 크면 해당 규칙이 결과를 예측하는데 있어 우수하다는 것을 의미한다.

- ① 신뢰도 (confidence)
- ② 순수도 (purity)
- ③ 지지도 (support)
- ④  향상도 (lift)

④ 향상도는 제품 A가 구매되지 않았을 때 제품 B의 구매확률에 비해 A가 구매됐을 때 품목 B의 구매확률의 증가비이다. 제품 A와 B의 구매가 서로 관련이 없는 경우 향상도가 1이 되며, 향상도가 1보다 크게 되면 예측이 우수함을 의미한다.

Section #

연관성 규칙

연관 규칙

1. 연관규칙분석이란

- 장바구니 분석, 서열분석이라고 불림
- 장바구니 분석 : 장바구니에 무엇이 같이 들어 있는지에 대한 분석
- 서열 분석 : A를 산 다음에 B를 산다

2. 연관규칙 지표 평가 방법

1) 지지도 (Support) ; $P(A \cap B)$

- 전체 거래 중 항목 A와 항목 B를 동시에 포함하는 거래의 비율

$$\text{Support} = P(A \cap B)$$

품목A와 품목B를 포함하는 거래수 / 전체 거래 수

2) 신뢰도 (Confidence) ; $(P(A \cap B)/P(A))$

- 항목 A를 포함한 거래 중에서 항목 A와 항목B가 같이 포함될 확률 (연관성의 정도를 파악)

$$\text{Confidence} = P(B|A) = P(A \cap B) / P(A)$$

지지도(Support) / $P(A)$


3) 향상도 (Lift) ; $(P(A | B)/P(A) = P(A \cap B) / P(A)*P(B))$

- A가 구매되지 않았을 때 품목 B의 구매확률에 비해 A가 구매됐을 때 품목 B의 구매확률의 증가비
- 연관규칙 $A \rightarrow B$ 는 A와 B의 구매가 서로 관련이 없는 경우에 향상도가 1이 됨

$$\text{Lift} = P(B|A) / P(B) = P(A \cap B) / P(A)P(B)$$

신뢰도 / $P(B)$

신뢰도를 item B의 발생확률로 나눈 것으로서, B의 확률대비, A가 발생할 때 B가 발생할 확률이다.



집합관계

20. [데이터 분석] 아래 거래 전표에서 연관 규칙 “A — B”의 향상도는 얼마인가? (소수점 첫째자리에서 반올림)

아래

물 품	거래건수
{A}	100
{B, C}	100
{C}	100
{A, B, C, D}	50
{B, C}	200
{A, B, D}	250
{A, C}	200

- ① 30%
- ② 50%
- ✓ ③ 83%
- ④ 100%

③ 향상도를 $\frac{\frac{300}{1000}}{\frac{600}{1000} \times \frac{600}{1000}} = \frac{10}{12} = 0.833$ 계산하면 $\cong 0.83$